浙江大学

本科生毕业论文

文献综述和开题报告

学生姓名 胡炘炎

学生学号 3210102517

指导教师 褚志轩

年级与专业 2021 计算机科学与技术

所在学院 计算机科学与技术学院

一、题目：基于知识图谱的大模型隐晦恶意检测

二、指导教师对文献综述和开题报告的具体要求：

1. 系统性覆盖核心领域，需完整涵盖研究领域现状，包括：

（1）大语言模型（LLM）安全风险和防御技术；

（2）知识图谱在内容安全中的应用，重点梳理语义推理、关系图谱构建方法。

要求包含近 3 年顶会论文及权威期刊文献占比不低于 40%，外文文献占比不低于 60%

2. 进行有一定深度的批判性分析，需指出现有研究的不足并分析未来研究的改进方向。

3. 聚焦创新性，明确研究的至少 2-3 个核心创新点。

4. 论证技术可行性和研究方案完整性，绘制技术路线图，明确研究内容和研究方法。

5. 翻译至少一篇核心参考文献，涵盖文章主要内容。

6. 遵守学术规范，注意内容的严谨性和用语的专业性，按照标准文献引用格式。

指导教师（签名）_____

2025 年 3 月 1 日

目　录

一、文献综述 1
1. 背景介绍 1
1.1 大语言模型的研究背景 1
1.2 大语言模型的安全问题 2
2. 国内外研究现状 2
2.1 研究方向及进展 2
2.2 存在问题 5
3. 研究展望 6
4. 参考文献 6
二、开题报告 9
1. 问题提出的背景 9
1.1 背景介绍 9
1.2 本研究的意义和目的 10
2. 论文的主要内容和技术路线 10
2.1 主要研究内容 10
2.2 技术路线 11
2.3 可行性分析 12
3. 研究计划进度安排及预期目标 13
3.1 进度安排 13
3.2 预期目标 14
4. 参考文献 14
三、外文翻译（仿宋 3 号加黑） 16
四、外文原文（仿宋 3 号加黑） 24

一、文献综述

1. 背景介绍

近年来，大规模预训练语言模型（Large Language Models，LLMs）发展突飞猛进，尤其是在自然语言处理、多模态推理等领域的突破性进展，极大地推动了人工智能技术的产业化落地。GPT-4、LLaMA、DeepSeek等模型凭借其千亿级参数规模与强大的泛化能力，已在医疗诊断[1]、金融风控[2]、代码生成[3]等场景中展现出显著价值。

然而，大语言模型的快速发展和应用部署也引发了对其潜在风险的广泛关注。随着模型复杂性与应用范围的扩展，其安全威胁呈现隐蔽性、多样性和跨场景传播的特点，由此可能引发一系列道德和法律的问题。因此，大语言模型的安全性问题亟待解决。本文对大语言模型的安全问题做了整体性的调研，总结了国内外研究的主要安全问题和防御方法，分析了研究中存在的问题并设想了未来可能的研究方向,从而为本次论文题目的确定锚定了方向。

1.1 大语言模型的研究背景

大语言模型（Large Language Models，LLMs）的底层技术框架以Transformer网络结构为核心[7]。该架构由多个功能模块的级联堆叠构成，每个Transformer模块内部包含自注意力计算单元和前馈神经网络两个核心组件，并通过残差连接机制实现跨层特征融合。其革命性的自注意力机制通过动态权重分配,使模型在处理特定语义单元时能并行关联上下文中的多维信息。尽管Transformer最初为神经机器翻译系统设计，但后续研究表明，基于该架构的预训练语言模型通过参数微调策略，可突破传统任务导向型模型的局限性。

典型的大语言模型具有超大规模参数特征，其参数量级普遍达到千亿级别，并依托互联网级多源异构语料库进行训练。具有代表性的技术体系包括OpenAI研发的GPT-3[8]与GPT-4[9]系列模型、Meta开源的LLaMA架构[10]，以及国内研究机构开发的DeepSeek模型[11]等。

在应用维度上，这类模型已突破自然语言处理的传统边界，广泛覆盖对话系统开发[12]、跨语言互译[13]、创意文本生成[14]等复杂认知任务。值得注意的是，当前LLMs与小规模语言模型在基础架构（如Transformer）和训练目标（如语言建模任务）层面具

有继承性，但前者在模型容量、训练数据规模、任务泛化能力以及算力消耗等方面呈现出数量级跃升。

构建离线部署的大语言模型通常遵循三阶段技术路径[4]：基础预训练阶段采用与传统机器学习相似的数据驱动范式，涵盖语料清洗、架构配置及分布式训练等环节；适配调优阶段通过指令微调（Instruction Tuning）和价值对齐（Alignment Tuning）技术，使模型习得任务解析能力并契合人类伦理规范；最终的应用增强阶段集成上下文学习（In-Context Learning）[8]、思维链推理（Chain-of-Thought Learning）[15]等前沿技术，显著提升人机交互的智能体验。

1.2 大语言模型的安全问题

随着研究的不断深入和应用的更加广泛,大语言模型面临的安全问题包括但不限于伦理道德问题、数据偏见、用户隐私保护及鲁棒性等问题[4]。在社会应用层面，恶意行为者可能通过传播虚假信息或辅助犯罪活动进行技术滥用[5]；在科研领域，LLMs 的专业化使用则涉及科学研究中的伦理考量与特定风险[6]。

2. 国内外研究现状

本节调查了当前大语言模型安全问题研究的现状,探讨了主要的针对大语言模型的对抗性行为，包括对抗攻击、越狱攻击、提示注入等。这些攻击可能操纵输出、绕过安全措施、泄露敏感信息并破坏服务，从而威胁系统的完整性、机密性和可用性。针对这些攻击行为，国内外的研究工作有了许多相应的防御方法，但也存在一些不足。

2.1 研究方向及进展

2.1.1 对抗攻击

对抗性攻击旨在通过微妙地修改输入文本来操纵模型的响应。根据攻击者是否能够访问模型的内部信息，对抗攻击可以分为 1）白盒攻击和 2）黑盒攻击。

白盒攻击假设攻击者完全掌握 LLM 的架构、参数和梯度信息，这使得攻击者能够通过直接优化对抗样本以针对模型的预测，构建出高效的对抗性示例。这类攻击通常可分为两个层次：1）字符级攻击[16]和 2）词级攻击[17]，其主要区别在于攻击的有效性和语义

隐蔽性。

黑盒攻击假设攻击者对目标LLM的参数知之甚少或完全不了解，仅通过API查询与模型交互。与白盒攻击不同，黑盒攻击采用间接且自适应的策略来利用模型漏洞。这类攻击通常通过操纵输入提示而非修改核心文本来实现。现有的LLM黑盒攻击进一步可以分为四类：上下文攻击，诱导攻击，LLM辅助攻击以及表格攻击。[18]

在实际应用中，对抗性防御对于确保大语言模型的安全性、可靠性和可信度至关重要。现有针对大语言模型的对抗防御策略，根据其主要关注点可大致划分为两类：1）对抗检测；2）鲁棒推理。

对抗检测方法旨在识别并标记潜在的对抗性输入，防止其影响模型输出。其核心目标是建立过滤机制，以区分良性提示与恶意指令。大多数针对大语言模型的对抗检测方法属于输入过滤技术，通过统计或结构异常识别并拒绝对抗性文本。例如：Jain 等人[19]利用困惑度(perplexity)检测对抗性提示：当经过良好校准的语言模型评估时，对抗性提示通常表现出更高的困惑度（偏离自然语言模式），通过设定困惑度阈值即可过滤此类输入。

鲁棒推理方法旨在通过调整模型内部机制或训练方式，使其从根本上具备对抗攻击的抵抗力。例如电路阻断（Circuit Breaking）[20]通过干预推理过程中特定的激活模式，直接阻断有害输出，且无需重新训练模型。

2.1.2 越狱攻击

与通过字符或词语级别扰动修改提示的对抗性攻击不同，越狱攻击通过人工构造或自动生成的越狱提示诱使大语言模型生成有害内容。其核心特征是：一旦模型被越狱，会对后续恶意查询持续生成有害回应，而对抗性攻击需对每个输入单独进行扰动。当前大多数越狱攻击研究聚焦于大语言模型的服务场景，遵循攻击者无法访问模型内部的黑盒威胁模型。

人工构造攻击通过设计对抗性提示词，针对目标大语言模型的特定漏洞进行突破。其核心策略是构造能绕过安全过滤机制、同时传递恶意请求的词语组合或文本结构。场景伪装（Scenario-based Camouflage）是人工构造攻击的常用方法，将恶意请求嵌套于复杂情境（如角色扮演、解谜游戏）中，模糊其危害性。例如：Li 等人[21]引导模型扮演易生成有害内容的人格角色，Easyjailbreak[22]将恶意查询置于假设性语境，Puzzler[23]将有害请求编码为谜题，其解答即对应有害输出。此外，注意力转移(Attention Shifting)通过语言复杂性转移模型对恶意意图的聚焦：StructuralSleight[24]通过句式结构变形干扰理解

自动化越狱攻击与依赖专家经验的人工构造攻击不同，它是通过算法自主探索突破模型的越狱提示词。如 AutoDAN[25] 采用遗传算法进化提示词，通过迭代优化算法生成高攻击成功率的对抗性提示词。随着研究的深入，也有尝试使用大模型辅助攻击，如 Masterkey[26]训练通用攻击模型实现对多模型的迁移攻击。

针对黑盒大语言模型的越狱攻击，现有防御方法根据干预阶段可分为输入防御和输出防御。

输入防御通过对用户输入进行预处理，改写净化提示词模糊其恶意意图，从而消解越狱攻。如：SmoothLLM[27]：通过随机采样扰动提示词，破坏对抗性结构的完整性；SemanticSmooth[28]搜索语义相似的安全替代表达，保留语义的同时消除有害内容；SelfDefend[29]移除高困惑度的对抗性 token。输入防御通过前端干预降低攻击成功率，但可能因过度过滤导致正常用户体验下降，需平衡安全性与可用性。

输出防御通过监控大语言模型的生成内容，识别潜在有害输出，并在检测到风险时触发拒绝响应机制。例如 APS 和 DPP[30] 基于预训练的安全分类器对输出评分，低于安全阈值的响应被拦截。输出防御通过后置拦截降低风险，但可能因过度保守限制模型实用性，需结合动态阈值调整与上下文理解优化。

2.1.3 提示注入

提示注入攻击通过在正常提示中嵌入恶意指令，操纵大语言模型生成非预期输出。提示注入聚焦大语言模型服务系统中的黑盒提示注入攻击，同样分为人工构造攻击与自动化攻击两类。

人工构造攻击需依赖专家经验设计注入提示，利用模型漏洞实施攻击。如 PROMPTINJECT[31] 与 HOUYI[32]通过在提示末尾附加恶意命令，或使用忽略上下文的特殊提示词诱导模型泄露敏感信息。自动化攻击通过算法自动生成或优化恶意提示，突破手工构造方法的局限性。如 Deng 等人[33]基于大语言模型迭代生成并优化攻击提示，结合持续性安全评估；Liu 等人[34]提出梯度引导的通用提示注入数据生成方法，可绕过防御机制。

针对提示注入攻击的防御旨在阻断恶意指令对模型输出的影响。与越狱防御类似，现有方法可分为输入防御与对抗性微调两类。

输入防御通过预处理输入提示消除潜在注入风险，无需修改模型核心架构。如结构化输入[35]可以将用户输入划分为指令与数据两个独立字段，避免指令与数据混合导致注入漏洞。对抗性微调通过增强模型对合法指令与恶意注入的区分能力实现防御。如 Jatmo[36]

对目标模型进行微调，将其能力限制在预定义的任务范围内，降低对任意指令的响应敏感性，但会牺牲模型泛化性与灵活性。

提示注入攻击揭示了 LLM 系统在指令鲁棒性层面的安全隐患，需结合输入过滤、输出监控与模型强化学习等多维度防御策略应对。

2.2 存在问题

随着模型开放性与应用场景复杂度的提升，以 ChatGPT、DeekSeek 为代表的大语言模型安全威胁正从传统的对抗样本攻击、数据隐私泄露，演变为更具隐蔽性和系统性的新型风险。核心缺陷包括：

1. 对抗性输入敏感性：大语言模型采用梯度下降优化方法，易受对抗性提示工程操控

2. 训练数据偏见传递：预训练阶段吸收的庞杂语料隐含偏见、虚假信息等风险知识，可能会放大社会偏见与有害内容。

3. 幻觉放大效应：生成看似合理但错误或无意义的信息

此类安全挑战的根源在于 LLMs 的黑盒特性和对统计模式的依赖而非真实语义理解[37]。一方面，模型内部知识表示的高度非线性使得恶意行为难以通过输入输出端直接观测。另一方面，大语言模型的构建一直被发生统计策略（statistics-of-occurrence strategy）所主导[37]：大语言模型由复杂的深度神经网络在大量未标记的文本上进行训练产生，利用有关单词和短语共现的统计信息，以产生类似于人类可能产生的行为，但大语言模型对文本中的语义关系理解的程度并不足够。因此如越狱攻击中，对于添加了技巧性、针对性修饰的提示词，往往不能准确解读出攻击者的真实意图。

同时，现有研究多聚焦于显性恶意内容的识别或主观恶意攻击的防御，但对隐晦恶意语义、跨越上下文的潜在恶意内容等新型威胁缺乏系统性防御框架。例如，输入的提示词并不存在明显的危险内容，也不属于典型的攻击方式，而是用户无意或某一语义潜在地具有恶意倾向。对于这一方面，当前的大模型尚显脆弱。政策层面，中国《生成式人工智能服务管理暂行办法》与欧盟《人工智能法案》均明确要求建立“风险可控、可追溯”的 LLMs 治理体系，亟需融合知识驱动与数据驱动的检测范式创新。

在此背景下，基于语义分析的结构化逻辑建模、多跳因果推理与动态风险评估，成为破解隐晦恶意检测难题的关键技术路径。

3．研究展望

现有防御方法在现实场景中面临多重局限，包括泛化性不足、效率低下、依赖白盒权限、适应性差等。构建真正实用的防御体系需要着眼于以下维度：

1. 通用性

防御方案需跨越模型架构与模态边界。当前防御多针对特定架构（如纯文本或单模态模型）设计，难以覆盖视觉-语言多模态系统等复杂场景。理想方案应提供跨模型家族的统一防御接口，支持快速部署到异构 AI 基础设施。

2. 黑盒兼容性

90%以上的商业 API 仅开放输入/输出接口，防御者无法访问模型内部参数或梯度。面向真实防御场景的核心约束需发展纯黑盒防御技术,例如基于输入内容语义分析的检测和语义过滤。

3. 可解释性

现有的防御方法大多数本质上是一个二分类器，缺乏具体的逻辑推理过程，易面临判断错误、难以追溯等情况。有研究尝试使用带推理过程的数据训练安全护栏，激活其推理思考能力[38]，可以增强防御系统的准确性和可解释性

4. 效率性

对抗训练等传统方法需消耗数千 GPU 小时进行全模型微调，成本难以承受。外置推理护栏也会增加检测时间，可能影响用户体验[38]。未来方向应在安全性和效率性上取得平衡，探索出轻量级、高安全性的防御方法。

4．参考文献

[1] Johnson, R., Smith, A., & Lee, B. (2024). Clinical decision support via multimodal LLMs: Opportunities and risks. Proceedings of the AAAI Conference on Artificial Intelligence, 38(1), 1234-1245.

[2] Wang, L., Zhang, Y., & Chen, H. (2023). Adversarial robustness in financial fraud detection: A knowledge graph approach. Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, 456-467.

[3] Chen, Z., Liu, X., & Sun, M. (2023). CodeXGLUE: A machine learning benchmark dataset for code understanding and generation. Proceedings of the 45th International Conference on Software Engineering, 789-800.

[4] X. Huang, W. Ruan, W. Huang, G. Jin, Y. Dong, C. Wu, S. Bensalem, R. Mu, Y. Qi, X. Zhao et al., “A survey of safety and trustworthiness of large language models through the lens of verification and validation,” arXiv prepr. arXiv:2305,11391, 2023.

[5] D. Kang, X. Li, I. Stoica, C. Guestrin, M. Zaharia, and T. Hashimoto, “Exploiting programmatic behavior of LLMs: Dual-use through standard security attacks,” arXiv prepr. arXiv:2302,05733, 2023.
[6] A. Birhane, A. Kasirzadeh, D. Leslie, and S. Wachter, “Science in the age of large language models,” Nat. Rev. Phys., vol. 5, no. 5, pp. 277–280, May 2023.
[7] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, “Attention is all you need,” in Adv. Neural Inf. Process. Syst. 30 (NeurIPS 2017), I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, Eds., vol. 30. Curran Associates, Inc., 2017.
[8] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, and D. Amodei, “Language models are few-shot learners,” in Proc. 34th Int. Conf. Neural Inf. Process. Syst., ser. NIPS’20. Red Hook, NY, USA: Curran Associates Inc., 2020.
[9] OpenAI, “GPT-4 technical report,” arXiv e-prints 2303,08774, 2023.
[10] H. Touvron, T. Lavril, G. Izacard, X. Martinet, M.-A. Lachaux, T. Lacroix, B. Rozière, N. Goyal, E. Hambro, F. Azhar et al., “Llama: Open and efficient foundation language models,” arXiv prepr. arXiv:2302,13971, 2023.
[11] DeepSeek-AI, et al. (2025). DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning. *arXiv preprint arXiv:2501.12948*.
[12] J. Wei, S. Kim, H. Jung, and Y.-H. Kim, “Leveraging large language models to power chatbots for collecting user self-reported data,” arXiv prepr. arXiv:2301,05843, 2023.
[13] C. Lyu, J. Xu, and L. Wang, “New trends in machine translation us ing large language models: Case examples with chatgpt,” arXiv prepr. arXiv:2305,01181, 2023.
[14] N. Simon and C. Muise, “TattleTale: Storytelling with planning and large language models,” in ICAPS Workshop Sched. Plan. Appl., 2022.
[15] J.Wei, X. Wang, D. Schuurmans, M. Bosma, F. Xia, E. Chi, Q. V. Le, D. Zhou et al., “Chain-of-thought prompting elicits reasoning in large language mod els,” NeurIPS, vol. 35, pp. 24824–24837, 2022.
[16] N. Boucher, I. Shumailov, R. Anderson, and N. Papernot, “Bad charac ters: Imperceptible nlp attacks,” in IEEE S&P, 2022.
[17] D. Jin, Z. Jin, J. T. Zhou, and P. Szolovits, “Is bert really robust? a strong baseline for natural language attack on text classification and entailment,” in AAAI, 2020.
[18] J. Wang, Z. Liu, K. H. Park, Z. Jiang, Z. Zheng, Z. Wu, M. Chen, and C. Xiao, “Adversarial demonstration attacks on large language models,” arXiv preprint arXiv:2305.14950, 2023.
[19] N. Jain, A. Schwarzschild, Y. Wen, G. Somepalli, J. Kirchenbauer, P.-y. Chiang, M. Goldblum, A. Saha, J. Geiping, and T. Goldstein, “Baseline defenses for adversarial attacks against aligned language models,” arXiv preprint arXiv:2309.00614, 2023.
[20] A. Zou, L. Phan, J. Wang, D. Duenas, M. Lin, M. Andriushchenko, J. Z. Kolter, M. Fredrikson, and D. Hendrycks, “Improving alignment and robustness with circuit breakers,” in NeurIPS, 2024.
[21] J. Li, Y. Liu, C. Liu, L. Shi, X. Ren, Y. Zheng, Y. Liu, and Y. Xue, “A cross-language investigation into jailbreak attacks in large language models,” arXiv preprint arXiv:2401.16765,

2024.
[22] W. Zhou, X. Wang, L. Xiong, H. Xia, Y. Gu, M. Chai, F. Zhu, C. Huang, S. Dou, Z. Xi et al., “Easyjailbreak: A unified framework for jailbreaking large language models,” arXiv preprint arXiv:2403.12171, 2024.
[23] X. Shen, Z. Chen, M. Backes, Y. Shen, and Y. Zhang, ““do anything now”: Characterizing and evaluating in-the-wild jailbreak prompts on large language models,” in ACM CCS, 2024.
[24] B. Li, H. Xing, C. Huang, J. Qian, H. Xiao, L. Feng, and C. Tian, “Structuralsleight: Automated jailbreak attacks on large language models utilizing uncommon text-encoded structure,” arXiv preprint arXiv:2406.08754, 2024.
[25] X. Liu, N. Xu, M. Chen, and C. Xiao, “AutoDAN: Generating stealthy jailbreak prompts on aligned large language models,” in ICLR, 2024.
[26] G. Deng, Y. Liu, Y. Li, K. Wang, Y. Zhang, Z. Li, H. Wang, T. Zhang, and Y. Liu, “Masterkey: Automated jailbreaking of large language model chatbots,” in NDSS, 2024.
[27] A. Robey, E. Wong, H. Hassani, and G. J. Pappas, “Smoothllm: Defending large language models against jailbreaking attacks,” arXiv preprint arXiv:2310.03684, 2023.
[28] J. Ji, B. Hou, A. Robey, G. J. Pappas, H. Hassani, Y. Zhang, E. Wong, and S. Chang, “Defending large language models against jailbreak attacks via semantic smoothing,” arXiv preprint arXiv:2402.16192, 2024.
[29] X. Wang, D. Wu, Z. Ji, Z. Li, P. Ma, S. Wang, Y. Li, Y. Liu, N. Liu, and J. Rahmel, “Selfdefend: Llms can defend themselves against jailbreaking in a practical manner,” arXiv preprint arXiv:2406.05498, 2024.
[30] C. Xiong, X. Qi, P.-Y. Chen, and T.-Y. Ho, “Defensive prompt patch: A robust and interpretable defense of llms against jailbreak attacks,” arXiv preprint arXiv:2405.20099, 2024.
[31] F. Perez and I. Ribeiro, “Ignore previous prompt: Attack techniques for language models,” in NeurIPS Workshop, 2022.
[32] Y. Liu, G. Deng, Y. Li, K. Wang, Z. Wang, X. Wang, T. Zhang, Y. Liu, H. Wang, Y. Zheng et al., “Prompt injection attack against llm integrated applications,” arXiv preprint arXiv:2306.05499, 2023.
[33] B. Deng, W. Wang, F. Feng, Y. Deng, Q. Wang, and X. He, “Attack prompt generation for red teaming and defending large language mod els,” in EMNLP, 2023.
[34] X. Liu, Z. Yu, Y. Zhang, N. Zhang, and C. Xiao, “Automatic and universal prompt injection attacks against large language models,” arXiv preprint arXiv:2403.04957, 2024.
[35] S. Chen, J. Piet, C. Sitawarin, and D. Wagner, “Struq: Defending against prompt injection with structured queries,” USENIX Security, 2025.
[36] J. Piet, M. Alrashed, C. Sitawarin, S. Chen, Z. Wei, E. Sun, B. Alomair, and D. Wagner, “Jatmo: Prompt injection defense by task-specific f inetuning,” arXiv preprint arXiv:2312.17673, 2023.
[37] L. M. Titus, “Does chatgpt have semantic understanding? a problem with the statistics-of-occurrence strategy,” Cognitive Systems Research, vol. 83, p. 101174, 2024.
[38] Yue Liu, Hongcheng Gao,Shengfang Zhai, Jun Xia,Tianyi Wu, Zhiwei Xue, Yulin Chen, Kenji Kawaguchi, Jiaheng Zhang, Bryan Hooi, “GuardReasoner: Towards Reasoning-based LLM Safeguards”, arXiv preprint arXiv: 2501.18492

二、开题报告

1. 问题提出的背景

近年来，以 GPT-4、LLaMA、DeepSeek 为代表的大语言模型（Large Language Models，LLMs）发展突飞猛进，已在科研、教育、医疗等领域展现出了显著的价值，极大地推动了人工智能技术的产业化落地。然而随之而来的是一系列与大语言模型有关的安全问题，包括道德和法律约束、幻觉和可解释性等。经过调研发现，现有防御方法在现实场景中面临多重局限，包括泛化能力不足、效率低下、依赖白盒权限、缺乏可解释性等。同时，现有研究多聚焦于显性恶意内容的识别或典型恶意攻击的防御，但对隐晦恶意语义、随机的潜在恶意内容等新型威胁缺乏系统性防御框架。因此，针对隐晦的恶意内容，亟需一套系统的、通用的、高效率的、可解释的防御手段。

1.1 背景介绍

知识图谱（Knowledge Graph，KG） 是一种以结构化的形式描述现实世界中实体、概念及其关系的技术体系，旨在将碎片化信息转化为机器可理解、可推理的语义网络。其背景可追溯至 20 世纪 60 年代的语义网络与知识表示研究，而现代知识图谱的兴起则源于互联网时代对海量数据高效管理与智能应用的需求。2012 年，Google 率先推出知识图谱产品，通过整合多源异构数据构建实体关系网络，显著提升了搜索引擎的语义理解能力，标志着知识图谱进入大规模应用阶段。随着人工智能技术的演进，知识图谱逐渐成为认知智能的核心基础设施，通过图结构存储（如 RDF、属性图）和逻辑推理（如 OWL、规则引擎），它能够揭示数据间的隐含关联，支持复杂推理、动态补全和跨领域知识融合。

当前，知识图谱已广泛应用于搜索引擎、智能问答、金融风控、医疗诊断等领域，并与大语言模型结合，弥补生成式 AI 在事实准确性上的不足，推动人机协同向更深层次的语义理解与决策迈进[1]。

知识图谱（KGs）与大语言模型（LLMs）的融合体现了“显式知识”与“参数化知识”的互补性，两者通过协同作用推动知识计算领域的范式转变。一方面，LLMs 通过其强大的自然语言处理能力，显著优化了知识图谱的构建与补全流程。例如，LLMs 能够从海量非结构化文本中高效提取实体、关系及事件，并通过上下文理解能力解决知识图谱构建中的语义歧义问题，从而降低人工标注成本并提升知识覆盖范围[2]。另一方面，知识图谱

为 LLMs 提供了结构化知识的高精度支持，通过注入显式知识增强模型的逻辑推理能力[3]、缓解幻觉问题[4]，并改善其在长尾知识、数值处理等场景下的表现。例如，在问答任务中，知识图谱可为 LLMs 提供可验证的事实依据，提升回答的准确性与可解释性[5]。

两者的结合进一步催生了“混合知识表示”的新范式：LLMs 的泛化能力与知识图谱的精确性相互补充，共同支撑复杂推理任务。LLMs 可通过知识图谱中的结构化关系优化对文本隐含逻辑的推理[6][7]，而知识图谱则依赖 LLMs 的语义解析能力扩展其动态更新与跨领域适配性。这种双向增强不仅加速了知识工程管道的自动化，还为医疗[8]等垂直领域提供了更可靠的决策支持框架，体现了从“知识存储”到“知识智能”的演进趋势。

种种研究表明，知识图谱与大语言模型的结合有助于解决大语言模型面对的挑战。

1.2 本研究的意义和目的

知识图谱凭借其结构化知识表征与逻辑推理能力，为提升大语言模型的安全性提供了创新路径。面对大语言模型易受到对抗性攻击或无法识别输入语义中潜在的恶意性内容的挑战，可通过知识图谱从以下方面为大语言模型提供安全防护：

1. 隐晦恶意内容或潜在风险语义识别：根据输入内容构建知识图谱，分析用户提示词中的实体（entity）、关系（relation），增强大语言模型对用户输入的语义理解能力，从而更好地识别出隐晦表达的恶意内容，或分析出语料中可能具有的潜在风险。
2. 增强拦截判断的准确率和可解释性：通过提示词知识图谱化，回溯 LLM 决策逻辑（如敏感话题的关联路径），定位潜在风险来源，从而提高对恶意内容判断的准确率，提供具有逻辑性的可解释依据。
3. 效率性和安全性的平衡：传统的对抗训练方法需要大量时间和算力支持，而新型的推理护栏延长了响应时间，影响用户体验[9]。轻量级的知识图谱，在强化模型推理能力的同时，降低成本和响应时间，取得效率低和安全性的平衡。

2. 论文的主要内容和技术路线

2.1 主要研究内容

本论文主要研究如何通过知识图谱的方法，更好地解决大语言模型隐晦恶意内容的检

测问题，具体可分为以下几个问题：

1. 恶意内容数据集的构建：获取充足的大模型提示词数据，其中应该涵盖无害样本、明显有害样本、隐晦恶意样本和含有潜在风险的样本，数据应带有标签以用于后续识别效果的评估。
2. 知识图谱的构建：对于数据集中的每条提示词内容，构建出相应的知识图谱。知识图谱中应包含提示词中的实体以及实体间的关系。构建的知识图谱应充分覆盖提示词语段中的所有实体，不能遗漏关系。
3. 带有知识图谱的提示词优化：将构建出的知识图谱嵌入到原有提示词中形成复合提示词，尝试优化该符合提示词的用语结构，以取得更好的检测效果。
4. 知识图谱技术对恶意内容识别效果的评估：在各种大语言模型上评估恶意内容识别的效果。应设计合理的评价指标，测试对象应涵盖不同模型、不同规模，测试内容包括原始提示词和带知识图谱的提示词，并对实验结果进行全面的分析和总结。
5. 效率分析：设计合理的效率评价指标，包括知识图谱构建的成本和时间、将知识图谱加入提示词对大模型响应时间的影响等。与其他研究结果进行比较分析，综合考虑安全性和效率性。

2.2 技术路线

下面将针对研究内容的各个阶段，分析可能采取的方法和技术。

1. 恶意内容数据集的构建：整合公开数据集（如 HateCheck[10]、COLD[11]）；建立网络爬虫框架采集社交媒体数据；利用对抗样本生成器（GAN），通过语义替换制造隐晦恶意样本。
2. 知识图谱的构建：可以采用预训练的知识图谱生成模型（如 BERT[12]）进行微调，也可以使用现成的知识图谱构建工具（如 kg-gen，SAC-KG[13]）。
3. 带有知识图谱的提示词优化：尝试采用主流的提示词工程技术，如零样本提示[14]/少样本提示[15],思维链提示[16]等，寻找效果更好的提示方法。
4. 知识图谱技术对恶意内容识别效果的评估：评价指标可参考大模型安全的主流评价指标，如 F1 score。测试模型应包括主流商业和开源大模型，如 Chat-GPT,DeepSeek，Llama 等，此类模型具有较强的推理能力或专业研发的安全护栏，可能提升效果不明显。可以着重测试小规模模型，如 deepseek-R1-1.5B/8B。

5. 效率分析：若使用预训练模型微调，可采用训练所用 GPU 规模和时间衡量知识图谱构建成本；使用现成工具则可以计算平均每条提示词知识图谱的生成时间。为了计算知识图谱引入的大模型响应时间开销，应分别测试原始提示词和复合提示词的计算时间加以对比，同时应将此额外响应时间与其他研究方法的时间开销进行比较。

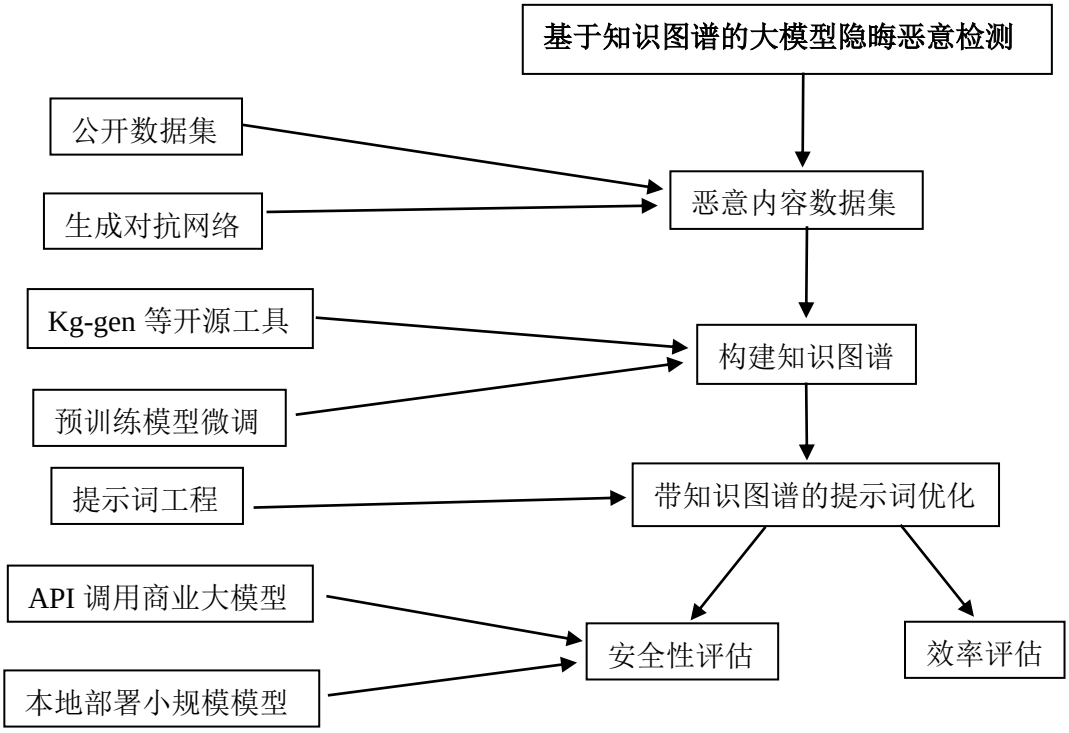

本研究的技术路线图

2.3 可行性分析

2.3.1 理论可行性

1.知识图谱与大语言模型协同的理论基础

知识图谱的结构化知识表征与逻辑推理能力已在大模型增强领域得到充分验证。研究表明，KG 能够通过显式知识注入弥补 LLMs 的"幻觉"缺陷，提升事实准确性[3][4]，其图结构中的实体关联路径可追溯推理逻辑，为可解释性提供理论支撑[5][6]。同时，LLMs 的语义理解能力已被证实可优化 KG 构建流程[2]，二者形成"参数化知识-结构化知识"的闭环互补机制，为隐晦恶意检测所需的深度语义分析奠定理论基础。

2.恶意语义识别的可计算性

隐晦恶意内容本质上具有可分解的语义特征：通过实体关联（如"特定药品+非法用途"）、关系异常（如"银行账户+异常操作指令"）等图模式表达潜在风险。知识图谱的图神经网络（GNN）算法已被成功应用于欺诈检测、风险推理等场景[8]，证明基于图结构的恶意语义建模具有数学可计算性。

2.3.2 方法可行性

1.技术工具链的成熟度

从知识图谱构建方面，当前已经有丰富的工具支持构建完整的知识图谱，如 SAC-KG 等工具支持从文本自动抽取 RDF 三元组[13]，BERT 微调方案已在 OpenKE 等框架中实现工业化部署。从效率控制方面：轻量化 KG 构建方案可将单条提示词处理时间控制在毫秒级[13]，与现有防御方法（如对抗训练）相比具有显著效率优势。

2.实验验证路径的完备性

研究设计覆盖"数据-方法-评估"全链条：数据集通过数据整合或对抗生成模拟真实场景中的隐晦攻击，确保威胁覆盖的全面性；采用 F1 score、响应延迟等量化指标，结合开源模型（如 DeepSeek-1.5B）与商业模型（ChatGPT）的对比测试，可有效验证方法泛化能力；效率分析引入成本-效益模型（如单位算力下的检测准确率提升），为实际部署提供决策依据。

2.3.3 现实意义可行性

多数 LLM 应用存在隐晦攻击防护缺口，医疗、金融等领域因合规要求亟需可解释的防御方案。本研究的轻量化 KG 方案响应时间增加预计低于 100ms，满足实时交互场景需求，较传统方法（如基于 API 调用的多模型串联）具有显著落地优势。通过构建"KG 语义防火墙"，可降低 LLMs 在敏感领域（如青少年教育、心理健康咨询）的误用风险。

3. 研究计划进度安排及预期目标

3.1 进度安排

1.开题报告后至中期检查（3 月 18 日-4 月 14 日）

1） 数据准备（3.18-3.31）

目标：搜集并整合公开数据集和其他数据，完成恶意内容数据集的构建。

2） 知识图谱构建（4.1-4.14）

目标：选定合适的知识图谱构建工具，基于数据集构建出完整、准确的知识图谱

3） 提示词优化与初步实验（4.1-4.14）

目标：完成知识图谱嵌入提示词的初步设计，并在单条提示词规模上验证可行性。预计在中期检查前形成完善的知识图谱提示词数据，为大规模实验做准备

2.中期检查后至论文提交（4 月 14 日-5 月 12 日）

1）全面实验与效果验证（4.14-4.27）

目标：在主流模型上完成效果评估与效率分析。扩展实验规模，覆盖 5 类模型（商业/开源、大/小规模）量化响应延迟（原始提示词 vs. 复合提示词），对比传统防御方法。

2）结果分析与论文撰写（4.28-5.4）

目标：完成实验数据分析，绘制数据分析对比图表，撰写论文主体内容。

3）论文终稿完善（5.5-5.12）

目标：完成论文修订、查重与格式调整，提交论文定稿。

3.2 预期目标

1.构建出完整、准确的隐晦恶意提示词—知识图谱数据集。

2.在主流模型上测试隐晦恶意检测效果，预计达到当前研究相近或更好的评估结果。

3.限制知识图谱对大模型响应的额外开销，预计每条输入引入的额外开销不超过 100ms

4．参考文献

[1] Linyao Yang, Hongyang Chen, Zhao Li, Xiao Ding, and Xindong Wu. Chatgpt is not enough: Enhancing large language models with knowledge graphs for fact-aware language modeling. arXiv, 2023.

[2] Mirza Mohtashim Alam, Md Rashad Al Hasan Rony, Mojtaba Nayyeri, Karishma Mohiuddin, MST Mahfuja Akter, Sahar Vahdati, and Jens Lehmann. Language model guided knowledge graph embeddings. IEEE Access, 10:76008–76020, 2022.

[3] Yih W-t, Richardson M, Meek C, Chang M-W, Suh J (2016) The value of semantic parse labeling for knowledge base question answering. In: Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers). pp. 201–206

[4] Ji Z, Liu Z, Lee N, Yu T, Wilie B, Zeng M, Fung P (2022) Rho (ρ): Reducing hallucination in open-domain dialogues with knowledge grounding. arXiv preprint arXiv:2212.01588.

Accessed 26 July 2023
[5] Yixin Ji, Kaixin Wu, Juntao Li, Wei Chen, Mingjie Zhong, Xu Jia, and Min Zhang. 2024. Retrieval and Reasoning on KGs: Integrate Knowledge Graphs into Large Language Models for Complex Question Answering. In Findings of the Association for Computational Linguistics: EMNLP 2024, pages 7598–7610, Miami, Florida, USA. Association for Computational Linguistics.
[6] Guo T, Yang Q, Wang C, et al. Knowledgenavigator: Leveraging large language models for enhanced reasoning over knowledge graph[J]. Complex & Intelligent Systems, 2024, 10(5): 7063-7076.
[7] Wen Zhang, Yushan Zhu, Mingyang Chen, Yuxia Geng, Yufeng Huang, Yajing Xu, Wenting Song, Huajun Chen. Structure Pretraining and Prompt Tuning for Knowledge Graph Transfer. arXiv:2303.03922
[8] Youfu Yan, Yu Hou, Yongkang Xiao, Rui Zhang, Qianwen Wang. KNOWNET: Guided Health Information Seeking from LLMs via Knowledge Graph Integration. arXiv:2407.13598
[9] Yue Liu, Hongcheng Gao,Shengfang Zhai, Jun Xia,Tianyi Wu, Zhiwei Xue, Yulin Chen, Kenji Kawaguchi, Jiaheng Zhang, Bryan Hooi, “GuardReasoner: Towards Reasoning-based LLM Safeguards”, arXiv preprint arXiv: 2501.18492
[10] Paul Röttger, Bertram Vidgen, Dong Nguyen, Zeerak Waseem, Helen Margetts, Janet B. Pierrehumbert. HateCheck: Functional Tests for Hate Speech Detection Models. arXiv:2012.15606
[11] Jiawen Deng, Jingyan Zhou, Hao Sun, Chujie Zheng, Fei Mi, Helen Meng, Minlie Huang. COLD: A Benchmark for Chinese Offensive Language Detection. arXiv:2201.06025
[12] Jacob Devlin, Ming-Wei Chang, Kenton Lee, Kristina Toutanova. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. arXiv:1810.04805
[13] Hanzhu Chen, Xu Shen, Qitan Lv, Jie Wang, Xiaoqi Ni, Jieping Ye. SAC-KG: Exploiting Large Language Models as Skilled Automatic Constructors for Domain Knowledge Graphs. arXiv:2410.02811
[14] Jason Wei, Maarten Bosma, Vincent Y. Zhao, Kelvin Guu, Adams Wei Yu, Brian Lester, Nan Du, Andrew M. Dai, Quoc V. Le. Finetuned Language Models Are Zero-Shot Learners. arXiv:2109.01652
[15] Sewon Min, Xinxi Lyu, Ari Holtzman, Mikel Artetxe, Mike Lewis, Hannaneh Hajishirzi, Luke Zettlemoyer. Rethinking the Role of Demonstrations: What Makes In-Context Learning Work? arXiv:2202.12837
[16] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc Le, Denny Zhou. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. arXiv:2201.11903

三、外文翻译

大语言模型与知识图谱：机遇与挑战

1. 引言

大型语言模型（LLMs）以其在广泛自然语言任务中展示出的人类水平表现，包括一些需要人类知识的任务，已然席卷了知识表示（KR）领域乃至整个世界。随后，人们逐渐开始接受在某些语言模型的参数中表示知识的可能性。LLMs 的到来宣告了知识计算时代的到来，在这一时代中，KR 中的推理概念被扩展到了基于多种知识表示的众多计算任务中。

这是知识表示领域的一大步。长期以来，人们关注的是显式知识，例如嵌入在文本中的知识，有时也称为非结构化数据，以及以结构化形式存在的知识，如数据库和知识图谱（KGs）[123]。历史上，人类长期使用文本来将知识代代相传，直到大约 1960 年代，研究人员开始研究知识表示以更好地理解自然语言，并开发了早期系统，如麻省理工学院的 ELIZA[180]。在 2000 年代初，知识表示和语义网社区共同努力，在网页规模上标准化了广泛使用的知识表示语言，如 RDF[121]和 OWL[55]，利用这些语言的大规模知识库因其有助于图形结构而更广泛地被称为 KGs[123]，使得逻辑推理和基于图形的学习成为可能。

随着 LLMs 的到来，这一转折点标志着从显式知识表示到重新关注显式知识和参数化知识混合表示的范式转变。作为显式知识表示的流行方法，KGs 现在被广泛研究用于与基于 Transformer 的 LLMs 的结合，包括预训练的掩码语言模型（PLMs）如 BERT[39]和 RoBERTa[104]，以及更近期的生成式 LLMs 如 GPT 系列[23]和 LLaMA[165]。一些工作使用 LLMs 来增强 KGs，例如知识提取、KG 构建和精炼，而另一些则使用 KGs 来增强 LLMs，例如训练和提示学习，或知识增强。在本文中，考虑到两个方向，即 LLMs 用于 KGs 和 KGs 用于 LLMs，我们更好地理解了从显式知识表示到重新关注显式知识和参数化知识混合表示的转变。

一篇相关的综述论文[204]全面回顾了使用 LLMs 进行 KG 构建和推理，而我们的工作提供了更深入的转折点视角，不仅考虑了关系型 KGs，还包括以本体作为模式的 KGs，以及其他结构化知识的维度，包括表格数据[183]和数值[122]。关于 LLMs 和 KGs 交叉点的其他工作与本文涵盖的主题有少量重叠；例如，关于使用 LLMs 作为 KGs 的研究[5]，关于使用 KGs 增强 LLMs 的研究[185]，或关于在三个知识相关任务上比较 GPT-4 与 ChatGPT

和 SOTA 微调方法的研究——实体、关系和事件提取，链接预测，以及 KG 问答[204]。总体而言，这些论文都没有探讨转折点的具体应用意义。为此，本文总结了社区内的常见辩论点，介绍了一组综合主题的最新技术，其中 KGs 和 LLMs 被整合，并进一步提出了机遇和挑战。

2. 社区内的常见争论观点

在知识计算社区中，参数化知识与显式知识的结合使用是一个备受争议的话题，支持者和怀疑者各持己见。以下是一些常见争议点的总结：

知识表示与推理：

知识图谱（KGs）提供了一种结构化的知识表示方式，具有明确的关系，能够支持推理和推断[110]。批评者则认为，LLMs 中的参数化知识依赖于统计模式而非真正的理解和推理[13]。支持 LLMs（如 ChatGPT）的人则强调其从大规模文本语料库中泛化信息的能力，能够捕捉广泛的信息，并具备出色的语言理解能力。

一方面，由于缺乏显式知识表示，LLMs 可能会生成看似合理但错误或无意义的回答，例如“幻觉”[193]。此外，人们还怀疑 LLMs 是否能够学习方向性蕴含[96]或推断概念之间的包含关系[61]。

另一方面，构建 KGs 可能成本高昂。尽管训练 LLMs 也可能代价不菲，但它们可以轻松支持许多下游应用，将 AI 从幕后推向前台。因此，参数化知识并非 LLMs 的唯一目标。总结来说，与知识表示中表达能力和可判定性之间的经典权衡相比，在知识计算任务中使用显式知识和参数化知识时，我们面临的是精度与召回率之间的权衡。

高精度方法：

KGs 的成功很大程度上归功于其能够以高准确率提供关于实体的事实信息。例如，YAGO[154]声称其准确率超过 95%。同样，谷歌在其 KG 中也需要高准确率以支持实际应用，例如，Knowledge Vault 的半自动构建方法并未投入生产，部分原因是其无法在基准测试中达到预期的 99%准确率[179]。沿着这一思路，许多基于 LLMs 的 KG 补全方法未能达到这些高性能水平，例如 BERT 在[97, 167]中的表现，以及拥有数千亿参数的 GPT-3[4]。这表明需要基于 LLMs 开发新颖的高精度 KG 构建方法。

数值处理：

众所周知，LLMs 在处理数值方面存在困难。即使是简单的算术任务，LLMs 也可能表现不佳，正如 Big-bench 的一项研究[153]所强调的那样。这一缺陷也延伸到了 KG 补全任务[78]。多个 LLMs 在利用 Wikidata[169]中的数值事实（如个人的出生和死亡年份）进

行 KG 补全的能力上进行了评估。然而，没有一个测试模型能够准确预测哪怕一个年份。这引发了关于当前 LLMs 在预训练过程中是否正确记忆数值以支持后续 KG 补全使用的疑问。尽管像 PaLM[153]这样的 LLMs 在处理数字方面表现出一定的能力，但更常用的小型模型似乎难以胜任这一任务。当考虑到度量的复杂性以及多种数字格式和类型时，问题变得更加复杂。目前，修改 LLMs 以处理数值的问题仍未解决，这使得它们在数值 KG 补全中的应用似乎还远未实用。

总结来说，参数化知识与显式知识的结合使用在知识计算中展现了巨大的潜力，但也面临着精度、数值处理等多方面的挑战。未来的研究需要探索如何更好地整合这两种知识表示方式，以实现更高效、更准确的知识计算。

长尾知识：

对于知识计算社区（及更广泛的领域）来说，关于 LLMs 的一个关键研究问题是 LLMs 记住了多少知识[107]。研究表明，当处理随机的 Wikidata 事实时，特别是与长尾实体相关的事实时，LLMs 的表现显著下降，这在 PopQA 数据集[107]和其他数据集[133, 167]中得到了验证。这种效应可以追溯到实体在预训练语料库中出现的频率与 LLMs 记忆能力之间的因果关系[44]。即使是规模庞大的 LLMs，在尝试保留长尾实体信息时也面临困难[80]。 KGs 在提供长尾实体知识方面天然优于 LLMs[78, 167]，因此可以进一步帮助提高知识计算任务的召回率。

偏见、公平性及其他问题：

批评者认为，LLMs 可能会延续并放大训练数据中的偏见，导致有偏见的输出。如果训练数据包含刻板印象或歧视性信息，LLMs 可能会生成有偏见或歧视性的回答[113, 91]。另一方面，支持者认为偏见并非 LLMs 固有，而是反映了数据中嵌入的社会偏见。他们强调解决训练数据中的偏见并开发缓解技术的重要性[144, 134, 140]。一项调查[16]指出，自然语言处理（NLP）系统中的“偏见”有多种概念化形式，但并未被从业者深入探讨。KGs 也被广泛应用于下游任务中，嵌入在 KG 中的社会偏见也会被传播[56, 87]。特别是，本体创建通常包含由意见、动机和个人选择驱动的手动规则，这是偏见的来源之一[73, 43]。此外，KG 构建的自动化流程也表现出性别偏见[109]。

除了偏见和公平性之外，LLMs 还存在其他类似问题，包括（但不限于）版权侵犯和错误信息。总的来说，由于参数化知识的隐含性质，与显式知识相比，从 LLMs 中遗忘这些有害信息更为困难。

可解释性：

在需要可解释性和可解释性的场景中，KGs 通常更受青睐[28]，因为它们明确表示实体之间的关系，并提供结构化的知识表示。

对 LLMs 的怀疑者认为，这些模型缺乏透明度和可解释性，使得难以理解它们如何得出答案或建议。LLMs 的支持者承认可解释性方面的挑战，但认为最近的研究努力[8, 72]正在通过注意力机制、模型自省等技术提高 LLMs 的可解释性。

一些人还认为，思维链（Chain-of-Thoughts, CoT）[177]也可以提高 LLMs 的可解释性，尽管问题分解和精确回答子问题仍远未解决。归因评估和通过源段落和句子增强 LLMs 是另一个最近的研究主题，旨在提高其在问答中的可解释性[17]。

总结来说，LLMs 和 KGs 在长尾知识、偏见与公平性、可解释性等方面各有优劣。未来的研究需要探索如何更好地结合两者的优势，以解决这些挑战并推动知识计算领域的发展。

3. 机遇和愿景

本文需要回答的一个关键问题是，随着参数化知识的出现，我们有哪些新的机遇？以下是我们对参数化知识及其与显式知识潜在整合所带来的新机遇的一些思考：

1. 即时访问海量文本语料库：

正如引言中提到的，长期以来，人类通过文本来传递知识。因此，如今大量知识以文本形式存在。使用 LLMs 可以高速访问极大规模的文本语料库，最近甚至可以在消费级硬件上实现[65]。这使得 AI 开发者能够避免陷入以往在数据收集、准备、存储和查询方面的关键挑战。同时，这也减少了对信息检索领域的关键依赖。

2. 为许多子任务提供更丰富的知识：

尽管 LLMs 最突出的能力——问答和对话——仍受到严格审视，但不应忽视的是，LLMs 已显著推进并简化了知识工程流程中的许多传统任务。通过开箱即用、少量示例微调或少量提示（few-shot prompting），LLMs 在依存关系解析、结构化解析、实体识别和关系提取等任务上取得了进展。正如错误会在流程中传播，改进也是如此，从而使得 KG 构建达到了前所未有的规模和质量。

此外，LLMs 可以直接用于许多知识工程之外的下游任务。通过将显式知识（特别是结构化知识）注入 LLMs（例如通过检索增强方法），可以使显式知识更易于用于广泛的下游任务，进一步实现“知识就是力量”的愿景。

3. 更高级的语言理解能力：

仅凭 LLMs 本身就已显著推进了自然语言的“理解”，这可以从文本蕴含、摘要、释义检测和生成等任务中得到证明。这些能力对于使知识工程对语言变异、拼写错误、冗余以及其他人类书写、网络抓取和其他噪声文本特征具有鲁棒性至关重要。现在，通过结合参数化知识与显式知识的潜在新方法，有可能实现更高级的语言理解，不仅限于文本蕴含，还包括摘要和一致性生成等其他 NLP 任务。

4. 压缩带来整合：

传统知识工程中的一个重要步骤是整合和聚合冲突与一致的信息，通常需要复杂的方法来从句子、模式和约束中整合观察结果[149]。在 LLM 训练中，这种聚合是自动发生的。尽管这一步骤尚未完全被理解，但它为外包知识工程中的主要挑战带来了潜力。

总结来说，参数化知识的出现为知识工程领域带来了诸多新机遇，包括即时访问海量文本、提升子任务能力、增强语言理解以及自动化信息整合。未来，结合参数化知识与显式知识的进一步研究将为知识计算领域开辟更广阔的前景。

结合参数化知识与显式知识带来的上述新机遇，我们的愿景是双重的：

在显式知识优先的用例中，我们的愿景是，LLMs 将能够推动、提升并简化知识工程流程中的关键步骤，从而使得知识图谱在规模、质量和实用性方面达到前所未有的高度。

在参数化知识优先的用例中，我们的愿景是，KGs 将改进、验证并增强 LLM 的生成内容，从而显著提高 LLM 使用的可靠性和信任度。

这两种愿景既不是相互替代的关系，也不是相互依赖的关系。相反，我们认为，不同类型的用例将继续并存，其中一些用例更倾向于显式知识优先（可解释性强的）方法，而另一些则更倾向于参数化知识优先（黑箱式）方法。无论哪种情况，这两种方向都具有显著的协同效应潜力，能够为彼此带来巨大的益处。

总结来说，显式知识与参数化知识的结合不仅为知识工程和 LLM 应用开辟了新的可能性，还为不同用例提供了灵活的选择。未来的研究与实践将进一步探索如何最大化这两种知识表示方式的协同效应，以推动知识计算领域的持续发展。

4. 主要研究方向和相关挑战

在参数化知识与显性知识皆可利用的机遇与愿景之下，本节我们将近期在利用大型语言模型（LLMs）与知识图谱（KGs）方面的进展，归纳并呈现于四大主题之下。

4.1 大语言模型对于知识图谱：知识提取

知识图谱（KG）的构建是一项复杂的任务，需要从多种来源收集并整合信息，这些来源包括结构化、半结构化和非结构化数据。传统方法通常依赖于专门设计的模块，这些模块能够单独处理每种数据类型，但在面对结构多样且异质的内容时往往力不从心。然而，大型语言模型（LLMs）作为强大的自然语言处理（NLP）模型，经过广泛信息源的训练，使其特别适合执行知识提取任务。

4.2 大语言模型对于知识图谱：知识图谱构建

我们强调大型语言模型（LLMs）在提升知识图谱（KG）构建过程中所扮演的重要角色，聚焦于该领域的当前趋势、问题及尚未解决的疑问。首先，我们探讨链接预测，这是一种基于现有 KG 生成新事实的方法。接着，我们考察归纳链接预测，此方法旨在为未见过的关系预测三元组。随后，我们的关注点转向一种更为新颖的方法，即直接从 LLM 的参数化知识中提取三元组。作为本节的总结，我们讨论了基于 LLM 的 KG 构建方法所面临的挑战，包括处理长尾实体、数值数据的问题，以及这些方法的精确性考量。

4.3 大语言模型对于知识图谱：逻辑模式构建

知识图谱（KG）通常配备有本体模式（包括规则、约束和本体），以确保质量、便于知识访问、支持推理等。同时，一个独立的本体，通常代表概念性知识，有时包含逻辑，也可以被视为一个 KG。在这一部分，我们介绍大型语言模型（LLMs）应用于学习本体模式和管理本体的相关主题。

4.4 知识图谱对于大语言模型：训练和增强大语言模型

在 4.1 至 4.3 节中，我们探讨了利用大型语言模型（LLMs）于知识图谱（KGs）的三个不同方面。在本节中，我们将视线转向另一方向，即利用 KGs 服务于 LLMs。这里有几个维度。首先，KGs 可以作为 LLMs 的训练数据。其次，KGs 中的三元组可用于提示（prompt）构建。最后但同样重要的是，KGs 可以在检索增强型语言模型中作为外部知识使用。

4.4.1 知识图谱用于（预）训练大语言模型

知识图谱（KGs）通常包含从高度可信的来源提取的信息，经过后处理并由人工评估验证。由于仅依赖自然语言文本可能导致信息覆盖范围有限[187, 130, 1, 184]，KG 的信息已被整合进预训练语料库中。使用 KG 中的事实知识来预训练大型语言模型（LLMs）也注入了结构化知识[112]。KGs 与 LLMs 的这种整合，加之高效的提示（prompts），使得将世界知识注入语言模型并整合新发展的信息变得便捷[41]。此外，高资源语言知识库（KBs）中表达的知识已被转移到针对低资源语言调整的语言模型（LMs）中[201, 100]。

进一步地，基于 KGs 的知识来预训练 LMs 已显示出在生成和问答（QA）任务性能上的提升[30，142，120]。在另一种方法中，[166]提出了一种可解释的神经符号知识库，其中记忆由现有 KB 中实体和关系的向量表示组成。这些表示在预训练和微调期间被增强到一个 LM 中，使模型在知识密集型的 QA 任务中表现出色。

4.4.2 知识图谱用于构建提示词

近年来，知识图谱（KGs）与大型语言模型（LLMs）的整合受到了越来越多的关注。一方面，研究探索了通过提示（prompting）LLMs 来收集和提炼知识，以便将这些知识提供给最终用户。另一方面，还有一个较少探索的研究方向，即 KGs 与提示协同使用，以增强 LLMs 的能力，使其更加有效，同时更加可信。

多项研究利用 KGs 来丰富和微调提示的创建，相较于手动方法，显著提高了提示的数量、质量和多样性。KGs 已被用于单轮和多轮的支架式提示中，通过低成本的 KG 遍历路径，同时考虑有意义的学习模式，实现了大规模应用[90]。其他研究探讨了如何结合来自 KGs 等外部来源的显性知识来辅助提示工程，特别是通过提供实体的额外上下文（如属性、K 跳邻居），以帮助 LLMs 生成更好的预测[22]。像 KnowPrompt[31]这样的方法利用 KGs 将关系标签之间的语义和先验知识整合到关系提取的提示调优中，从而增强了提示构建过程，并通过结构化约束优化了其表示。

某些研究在 KG 推理任务中使用了 LLMs 和提示[34]，例如，LARK 利用查询中的实体和关系在抽象 KGs 中找到相关的子图上下文，然后使用分解的逻辑查询的 LLM 提示在这些上下文上进行链式推理，显著超越了之前的最先进方法。

5. 展望

总之，大型语言模型（LLMs）的最新进展标志着知识图谱（KG）研究的一个重要转折点。尽管关于如何结合它们优势的重要问题仍然悬而未决，但这些问题为未来的研究提供了令人兴奋的机遇。研究社区正在迅速调整其研究重点，出现了如 KBC-LM 研讨会[79]和 LM-KBC 挑战[151]等新论坛，资源大规模转向知识提取、整合和使用的混合方法。我们提出以下建议：

1. 不要因为范式转变而抛弃 KG：对于一系列可靠性或安全性至关重要的应用，结构化知识仍然是不可或缺的，我们概述了 KGs 和 LLMs 可以相互促进的多种方式。KGs 将继续存

在，不要仅仅因为潮流而抛弃它们。

2. 抛弃你的（管道）宠儿：LLMs 已经在 KG 和本体构建管道中的许多任务上取得了显著进展，甚至使一些任务变得过时。要非常仔细地检查即使是最成熟的管道组件，并持续与基于 LLM 的最新技术进行比较。

3. 保持好奇心，保持批判性：LLMs 可以说是过去几年人工智能研究中最令人印象深刻的成果。然而，公众和研究文献中存在大量夸大的声明和期望，应保持一定程度的批判性反思。特别是，对于所谓的“幻觉”问题，目前还没有根本性的解决方案。

4. 过去已结束，让我们开始新的旅程：LLMs 引发的进展以前所未有的方式颠覆了这一领域，并使得进入这一领域的门槛显著降低。现在是重新开始在知识计算相关领域的最佳时机。尽管当前转型的方向广泛开放，随着研究人员继续探索混合方法的潜力和挑战，我们可以预期在知识表示和处理方面取得新的突破，对从知识计算到自然语言处理（NLP）、人工智能（AI）及其他领域产生深远影响。

四、外文原文

Large Language Models and Knowledge Graphs: Opportunities and Challenges

1. Introduction

Large Language Models (LLMs) have taken Knowledge Representation (KR)—and the world— by storm, as they have demonstrated human-level performance on a vast spectrum of natural language tasks, including some tasks requiring human knowledge. Following this, people are gradually starting to accept the possibility of having knowledge represented in the parameters of some language models. The arrival of LLMs announces the era of Knowledge Computing, in which the notion of reasoning within KR is broadened to many computation tasks based on various knowledge representations.

This is a big step for the field of Knowledge Representation. For a long time, people focused on explicit knowledge, such as those embedded in texts, sometimes also known as unstructured data, and those in a structured form, such as in databases and knowledge graphs (KGs) [123]. Historically, for a long time, humans used texts to pass down their knowledge from one generation to another, until around the 1960s, when researchers started to study knowledge representation for better natural language understanding and developed early systems, such as ELIZA [180] at the MIT. In the early 2000s, the Knowledge Representation and the Semantic Web communities worked together to standardize the widely used knowledge representation languages, such as RDF [121] and OWL [55], at web scale, using which the large-scale knowledge bases are then more widely known as KGs [123], due to their helpful graph structures, enabling the both logical reasoning and graph-based learning.

This inflection point, with the arrival of LLMs, marks a paradigm shift from explicit knowledge representation to a renewed focus on the hybrid representation

of both explicit knowledge and parametric knowledge. As a popular approach for explicit knowledge representation, KGs are now widely investigated for the combination with Transformer-based LLMs, including pre-trained masked language models (PLMs) like BERT [39] and RoBERTa [104], and more recent generative LLMs like the GPT series [23] and LLaMA [165]. Some works use LLMs to augment KGs for, e.g., knowledge extraction, KG construction, and refinement, while others use KGs to augment LLMs for, e.g., training and prompt learning, or knowledge augmentation. In this paper, considering both directions, LLMs for KGs and KGs for LLMs, we present a better understanding of the shift from explicit knowledge representation to a renewed focus on the hybrid representation of both explicit knowledge and parametric knowledge.

A related survey paper [204] presents a comprehensive review of using LLMs for KG con struction and reasoning, while our work provides a more in-depth view of the inflection point, considering not only relational KGs but also KGs with ontologies as schemas, as well as other dimensions of structured knowledge, including tabular data [183] and numerical values [122]. Other works on the intersection of LLMs and KGs have a minor overlap with the topics covered in our paper; e.g., on studies using LLMs as KGs [5], on using KGs to augment LLMs [185], or on comparing GPT-4 with ChatGPT and SOTA fine-tuning methods on three knowledge-related tasks—entity, relation and event extraction, link prediction, and KG question answering [204]. Overall, none of these papers look into the implications of the inflection point with concrete applications. To this end, this paper summarises the common debate points within the community, introduces the state-of-the-art for a comprehensive set of topics where KGs and LLMs are integrated, and further presents opportunities and challenges.

2. Common Debate Points within the Community

The usage of parametric and explicit knowledge together is a topic of debate

in the Knowledge Computing community, with proponents and skeptics offering different perspectives. Below are some summaries of common points of contention.

Knowledge Representation and Reasoning: KGs offer a structured representation of knowledge with explicit relationships, enabling reasoning and inference [110]. Critics argue that parametric knowledge in LLMs relies on statistical patterns rather than true understanding and reasoning [13]. Proponents of LLMs like ChatGPT, highlight their ability to generalize from large-scale text corpora, capturing a range of information, and excellent language understanding capabilities. On the one hand, LLMs could generate plausible but incorrect or nonsensical re sponses, such as hallucinations, due to a lack of explicit knowledge representation [193]. There are also doubts on whether LLMs have the ability to learn directional entailments [96] or infer sub sumption between concepts [61]. On the other hand, KGs can be costly to build. While LLMs can be expensive to train too, they can be readily usable to support many downstream applications, bringing AI from the backstage to centre stage. Thus parametric knowledge is not the (only) destination for LLMs. To sum up, in comparison to the classic trade-off between expressiveness and decidability in Knowledge Representation, here we have the trade-off between precision and recall considering using explicit and parametric knowledge in Knowledge Computing tasks.

High Precision Methods: The success of KGs can largely be attributed to their ability to provide factual information about entities with high accuracy. For instance, YAGO [154] asserts an accuracy rate exceeding 95%. Similarly, Google necessitates high accuracy in its KG for operational use, e.g., the semi-automatical construction method of Knowledge Vault was not utilized in production, partly due to its inability to reach the desired 99% accuracy in their benchmark [179]. Along this line of thought, many LLM-based methodologies for KG completion fail to reach these high-performance levels, as exemplified by the performance of BERT in [97, 167], and GPT-3, equipped with hundreds of billions of parameters [4]. This calls for novel high precision methods for KG construction

based on LLMs.

Numerical Values: It is widely recognized that LLMs grapple with handling numerical val ues. Even straightforward arithmetic tasks can be a struggle for LMs, as highlighted in a study by Big-bench [153]. This shortcoming also extends to KG completion tasks [78]. Multiple LLMs have been evaluated on their ability to complete KGs using numerical facts from Wikidata [169], such as individuals' birth and death years. However, none of the tested models accurately pre dicted even a single year. This raises questions about the capability of current LLMs to correctly memorize numbers during pre-training in a way that enables them for subsequent use in KG completion. While LLMs like PaLM [153] demonstrate some proficiency in dealing with numbers, more commonly used smaller models seem ill-equipped for this task. The complexity escalates when considering the intricacies of metrics and diverse numbering formats and types. Currently, modifying LLMs to handle numerical values remains unresolved, making their utilization for numerical KG completion seem far from practical.

Long-tail Knowledge: One of the key research questions on LLMs for the Knowledge Com puting community (and beyond) is how much knowledge LLMs remember [107]. Investigations indicate that LLMs' performance significantly deteriorates when dealing with random Wikidata facts, specifically those associated with long-tail entities, in comparison to popular entities, as evidenced in the PopQA dataset [107] and other datasets [133, 167]. This effect can be traced back to a causal relationship between the frequency of an entity's appearance in the pre-training corpus and the LLMs' capacity for memorization [44]. Even sizable LLMs face difficulties when trying to retain information about long-tail entities [80]. KGs inherently present an advantage over LLMs through their provision of knowledge about long-tail entities [78, 167] and thus can further help improve the recall for Knowledge Computing tasks.

Bias, Fairness and Beyond: Critics argue that LLMs can perpetuate and amplify biases present in the training data, leading to biased outputs. LLMs may generate

biased or prejudiced responses if the training data contains stereotypes or discriminatory information [113, 91]. On the other hand, proponents argue that bias is not inherent to LLMs but reflects societal biases embedded in the data. They emphasize the importance of addressing bias in the training data and developing mitigation techniques [144, 134, 140]. A survey [16] argued that "bias" in Natural Language Processing (NLP) systems took various conceptualizations without being critically engaged by practitioners. KGs are also used in a plethora of downstream tasks, and social bi ases engraved in KG embeddings get propagated [56, 87]. Specifically, ontology creation, which generally comprises manual rules factored by opinions, motivations, and personal choices, is a source of bias [73, 43]. Also, automated pipelines for KG construction exhibit gender bias [109]. There are other similar concerns of LLMs beyond bias and fairness, including (but not limited to) copyright violation and misinformation. In general, due to the implicit nature of parametric knowledge, it is less straight forward to forget such toxic information from LLMs, compared to explicit knowledge.

Explainability and Interpretability: KGs are often preferred in scenarios where explain ability and interpretability are crucial [28], as they explicitly represent relationships between entities and provide a structured knowledge representation. Skeptics of LLMs argue that these models lack transparency and interpretability, making it difficult to understand how they ar rive at their answers or recommendations. Proponents of LLMs acknowledge the challenge of explainability but argue that recent research efforts [8, 72] are improving LLM's interpretabil ity through techniques like attention mechanisms, model introspection. Some also argue that Chain-of-Thoughts (CoT) [177] can also improve the explainability of LLMs, although question decomposition and precisely answering sub-questions with LLMs are still far from being solved. Attribution evaluation and augmentation of LLMs with e.g., source paragraphs and sentences is another recent research topic for improving their explainability in question

answering [17].

3. Opportunities and Visions

One of the key questions this paper needs to answer is, now with the emergence of parametric knowledge, what new opportunities do we have? Here are some of our thoughts on such new opportunities with the arrival of parametric knowledge and its potential integration with explicit knowledge.

1. Instant access to huge text corpora: As mentioned in the Introduction, for a long time, human beings passed down their knowledge in texts. Thus, a lot of knowledge these days are in textual form. Using LLMs gives access to extremely large text corpora at high speed, and recently even on consumer hardware [65]. This allows AI developers to avoid getting bogged down in previously critical challenges around data gathering, preparation, storage, and querying at scale. It also helps to reduce previously critical dependencies on the field of information retrieval.

2. Richer knowledge for many subtasks: Although the most prominent capabilities of LLMs, question answering and dialogue, are still under critical scrutiny, it should not be overlooked that LLMs have significantly advanced and simplified many traditional tasks of the knowledge engineering pipeline. Out-of-the-box, with fine-tuning on a few examples, or via few-shot prompting, LLMs have advanced many tasks such as dependency and structured parsing, en tity recognition, and relation extraction. And just as errors propagate along a pipeline, so do improvements, thus enabling KG construction at unprecedented scale and quality. Further more, LLMs are readily usable for many downstream tasks beyond knowledge engineering. By injecting explicit, and in particular structured, knowledge into LLMs, such as through retrieval augmented methods, one can make explicit knowledge more readily usable for such wide range of downstream tasks, further realising the vision of ‘Knowledge is power’.

3. Even more advanced language understanding: LLMs alone already significantly

ad vanced the “understanding” of natural language, as evidenced by tasks like textual entailment, summarization, paraphrase detection and generation, etc. These capabilities are critical to making knowledge engineering robust to linguistic variance, typographic errors, redundancy, and other features of human-written, web-scraped, and other noisy forms of text. Now with potential novel approaches to combining parametric knowledge with explicit knowledge, it is possible to have even more advanced language understanding, not only for textual entailments, but also for other NLP tasks, such as summarization and consistent generation.

4. Compression entails consolidation: An important step in traditional knowledge engineering is the consolidation and aggregation of conflicting and concurring pieces of information, requiring often elaborate methods for consolidating observations from sentences, patterns, and constraints [149]. In LLM training, an aggregation occurs automatically. Although this step is not entirely understood, it brings the potential for outsourcing a major challenge in knowledge engineering.

With the above new opportunities brought by the combination of parametric and explicit know ledge, our vision is two-folded:

In Explicit-Knowledge-First use cases, our vision is that LLMs will enable, advance, and simplify crucial steps in the knowledge engineering pipeline so much as to enable KGs at unprecedented scale, quality, and utility.

In Parametric-Knowledge-First use cases, our vision is that KGs will improve, ground, and verify LLM generations so as to significantly increase reliability and trust in LLM usage.

Both visions are neither alternatives, nor does one build upon the other. Instead, we believe that classes of use cases will continue to exist side-by-side, some of which favor Explicit-Knowledge First (scrutable) approaches, some of which favor Parametric-Knowledge-First (blackbox) ap proaches, with either of these having significant potential for benefiting from synergies of the two directions.

4.Key Research Topics and Related Challenges

With the opportunities and visions related to the availability of both parametric and explicit knowledge in place, in this section, we categorize, summarize, and present the recent developments in using LLMs and KGs under four different themes.

4.1 LLMs for KGs: Knowledge Extraction and Canonicalisation

KG construction is a complex task that demands collecting and integrating information from a wide array of sources, encompassing structured, semi-structured, and unstructured data. Traditional methods often rely on specific modules designed to process each data type in isolation and struggle when the content is diverse and heterogeneous in structure. However, LLMs are powerful NLP models trained on a broad spectrum of information sources, making them well-suited for knowledge extraction tasks. This section presents work that uses LLMs for knowledge extraction from various sources.

4.2 LLMs for KGs: Knowledge Graph Construction

We highlight the important role that LLMs play in improving KG construction, focusing on current trends, issues, and unanswered questions in this field. We start by discussing link prediction, which is a way to generate new facts given an existing KG. Next, we look at inductive link pre diction, a method that predicts triples for unseen relationships. Our focus then shifts to a more recent method where triples is directly extracted from the parametric knowledge of an LLM. As a conclusion of this section, we discuss the challenges of LLM-based methods for KG construction. These involve issues with long-tail entities, numerical values, and also the precision of these methods.

4.3 LLMs for KGs: Ontological Schema Construction

A KG is often equipped with an ontological schema (including rules, constraints and ontologies) for ensuring quality, enabling easier knowledge access,

supporting reasoning, etc. Meanwhile, an independent ontology, which usually represents conceptual knowledge sometimes with logics can also be regarded as a KG. In this part, we introduce topics that LLMs are applied to learn ontological schemas and to manage ontologies.

4.4 KGs for LLMs: Training and Accessing LLMs

In Sections 4.1 to 4.3, we discussed on three different aspects on using LLMs for KGs. In this section, we look into the other direction, i.e., using KGs for LLMs. There are a few dimensions here. Firstly, KGs can be used as training data for LLMs. Secondly, triples in KGs can be used for prompt construction. Last but not least, KGs can be used as external knowledge in retrieval augmented language models.

4.4.1 KGs for (Pre-)Training Language Models

KGs usually contain information extracted from highly trusted sources, post-processed, and vetted by human evaluations. Information from KGs has been integrated into the pre-training corpus since natural language text alone can lead to limited information coverage [187, 130, 1, 184]. Using factual knowledge from KGs to pre-train LLMs has also infused structured knowledge [112]. This integration of KGs with LLMs, along with efficient prompts, has made it convenient to inject world knowledge and incorporate new evolving information into language models [41]. Additionally, knowledge expressed in high-resource language KBs has been transferred into LMs tuned for low-resource languages [201, 100].

Furthermore, grounding knowledge from KGs to pre-train LMs has shown improvements in performance on generation and QA tasks [30, 142, 120]. In another approach, [166] proposed an interpretable neuro-symbolic KB, where the memory consists of vector representations of entities and relations from an existing KB. These representations are augmented to an LM during pre training and fine-tuning, enabling the model to excel in knowledge-intensive QA tasks.

4.4.2 KGs for Prompt Construction

The attention received by the integration of KGs and LLMs has grown recently. On the one hand, there is the explored direction of prompting LLMs for collecting and distilling knowledge in order to make it available to the end-users. On the other hand, there is the less explored research direction where KGs are used in synergy with prompts in order to enhance LLMs with capabilities making them more effective and, at the same time, trustworthy. A number of studies have leveraged KGs to enrich and fine-tune prompt creation resulting in a significant increase in prompt quantity, quality, and diversity compared to manual approaches. KGs have been employed in single and in multi-turn scaffolding prompts at scale, powered by numerous traversal paths over KGs with low authoring cost while considering the meaningful learning patterns [90]. Other studies have investigated how incorporating explicit knowledge from external sources like KGs can help prompt engineering, especially by giving additional contexts (e.g., attributes, K hop neighbors) of the entities in order to help the LLMs to generate better predictions [22]. Approaches like KnowPrompt [31] use KGs to incorporate semantic and prior knowledge among relation labels into prompt-tuning for relation extraction, enhancing the prompt construction process and optimizing their representation with structured constraints. Certain studies have utilized LLMs and prompts in the task of reasoning over KGs [34], e.g., LARK uses entities and relations in queries to find pertinent sub-graph contexts within abstract KGs, and then, performs chain reasoning over these contexts using LLM prompts of decomposed logical queries outer forming previous state-of-the-art approaches by a significant margin.

5. Outlook

In conclusion, the recent advances on large language models (LLMs) mark an important inflection point for knowledge graph (KG) research. While important questions on the ability to combine their strengths remain open, these offer exciting opportunities for future research. The community is already rapidly

adapting their research focus, with novel forums like the KBC-LM workshop [79] and the LM-KBC challenge [151] arising, and resources massively shifting towards hybrid approaches to knowledge extraction, consolidation, and usage. We give out the following recommendations:

1. Don’t throw out the KG with the paradigm shift: For a range of reliability or safety-critical applications, structured knowledge remains indispensible, and we have outlined many ways in which KGs and LLMs can fertilize each other. KGs are here to stay, do not just ditch them out of fashion.

2. Murder your (pipeline) darlings: LLMs have substantially advanced many tasks in the KG and ontology construction pipeline, and even made some tasks obsolete. Take critical care in examining even the most established pipeline components, and compare them continuously with the LLM-based state of the art.

3. Stay curious, stay critical: LLMs are arguably the most impressive artifact of AI research of the past years. Nonetheless, there exist a magnitude of exaggerated claims and expectations in the public as well as in the research literature, and one should retain a healthy dose of critical reflection. In particular, a fundamental fix to the so-called problem of hallucinations is not in sight.

4. The past is over, let’s begin the new journey: The advances triggered by LLMs have uprooted the field in an unprecedented manner, and enable to enter the field with significant shortcuts. There is no better time to start anew in fields related to Knowledge Computing, than now. Although the direction of the present transformation is widely open, as researchers continue to explore the potentials and challenges of hybrid approaches, we can expect to see new break throughs in the representation and processing of knowledge, with far-reaching implications for fields ranging from Knowledge Computing to NLP, AI, and beyond.

毕业论文（设计）文献综述和开题报告考核

导师对开题报告、外文翻译和文献综述的评语及成绩评定：

报告主题清晰，研究问题针对性强，对知识图谱与大模型结合进行隐晦恶意检测有初步分析。开题报告技术路线和进度安排合理。建议在后续研究中进一步加强实验数据集的多样性和评估指标的完善性，以提高检测效果的稳定性和可靠性。

成绩比例	文献综述（10%）	开题报告（15%）	外文翻译（5%）
分 值	8	13	4

导师签名_____

2025 年 3 月 20 日

学院盲审专家对开题报告、外文翻译和文献综述的评语及成绩评定：

开题报告选题前沿并具有一定的应用价值，目标明确，研究内容合理，技术路线基本可行，时间安排合理。 外文翻译专业词汇翻译准确。文献综述相关文献选择、分类、介绍、分析基本合理。文献综述和开题的内容过于单薄。参考文献的格式可进一步优化。

成绩比例	文献综述（10%）	开题报告（15%）	外文翻译（5%）
分 值	8	12	4

开题报告审核负责人（签名/签章）_____

2025 年 3 月 21 日